

Chương 3 Một số khái niệm cơ bản về thống kê

3.1 Giới thiệu

Kiến thức về các khái niệm cơ bản của thống kê là điều kiện tiên quyết cho việc nghiên cứu thiết kế khảo sát mẫu. Do đó, trong chương này, chúng ta xem xét một số khái niệm cơ bản này và mở rộng một số khái niệm cho các tình huống duy nhất để lấy mẫu.

Mục tiêu cuối cùng của thống kê là suy luận về một tổng thể từ thông tin chứa trong một mẫu. Tổng thể là một tập hợp các phép đo (hữu hạn hoặc vô hạn). Do đó, bước đầu tiên trong thống kê là tìm cách diễn đạt suy luận về một tổng thể hoặc mô tả một tập hợp các phép đo. Do đó, cách tóm tắt thông tin chính về tổng thể (vô hạn và hữu hạn), và về các mẫu từ những tổng thể đó là những khái niệm cơ bản đầu tiên sẽ được thảo luận.

Bước thứ hai trong thống kê là xem xét cách suy luận có thể được thực hiện về tổng thể từ thông tin chứa trong một mẫu. Đối với bước này, chúng ta phải xem xét phân phối xác suất của các đại lượng mẫu hoặc phân phối lấy mẫu. Kiến thức về phân phối xác suất liên quan đến mẫu cho phép chúng ta chọn các quy trình suy luận thích hợp và gán các phép đo tốt cho các suy luận đó.

Phương pháp suy luận chủ yếu được sử dụng là ước lượng. Chúng ta có thể muốn ước lượng tổng tài sản của một công ty, tỷ lệ cử tri ủng hộ ứng cử viên Jones hoặc số lượng người cắm trại sử dụng công viên trong một khoảng thời gian nhất định. Do đó, chúng ta phải hiểu các khái niệm cơ bản làm nền tảng cho việc lựa chọn công cụ ước lượng cho tham số tổng thể, phương pháp đánh giá độ tốt của nó và các khái niệm liên quan đến ước lượng khoảng. Vì độ lệch và phương sai của công cụ ước lượng xác định độ tốt của chúng, nên chúng ta cần xem xét các ý tưởng cơ bản liên quan đến kỳ vọng của một biến ngẫu nhiên và các khái niệm về phương sai và hiệp phương sai.

Các phần tiếp theo tuân theo thứ tự vừa đưa ra. Chúng ta bắt đầu với thảo luận về việc tóm tắt thông tin trong tổng thể và mẫu cho trường hợp **TỔNG THỂ VÔ HẠN** và sau đó là thảo luận về trường hợp **TỔNG THỂ HỮU HẠN**. Sau đó, chúng ta xem xét mô hình xác suất để lặp lại một thí nghiệm. Chúng tôi giải thích cách mà mô hình có thể được sử dụng để suy ra các đặc điểm của một tổng thể và thảo luận về các biến ngẫu nhiên, phân phối xác suất và phân phối lấy mẫu. Cuối cùng, chúng tôi trình bày các khái niệm cơ bản liên quan đến ước lượng điểm và khoảng.

3.2 Tóm tắt thông tin trong tổng thể và mẫu: Trường hợp tổng thể vô hạn

Việc nắm bắt các đặc điểm quan trọng của một **tập hợp lớn** các phép đo bằng cách xem danh sách các phần tử là không dễ, vì vậy chúng ta thường phải tóm tắt các phép đo thông qua việc sử dụng các kỹ thuật đồ họa hoặc kỹ thuật số. Mặc dù nhìn chung không có sẵn tất cả các phép đo trong tổng thể nghiên cứu, nhưng chúng ta vẫn có thể giả định một số hình dạng đồ họa hợp lý cho phân phối tần số tương đối của tổng thể này. Tất nhiên, chúng ta luôn có thể xây dựng biểu đồ tần số hoặc tần số tương đối cho một mẫu, vì các phép đo mẫu đã biết và sử dụng nó để đánh giá thực nghiệm hình dạng của tổng thể.


Khi phân phối tần số tương đối đã được thiết lập cho một tổng thể, chúng ta có thể sử dụng các lập luận xác suất để tính toán các đặc trưng mẫu như giá trị trung bình, phương sai và độ lệch chuẩn. Các đại lượng tương tự có thể được tính toán trực tiếp từ các phép đo trên mẫu.

Để minh họa, giả sử rằng một tổng thể bao gồm một số lượng lớn các số nguyên, 0, 1, 2, ..., 9, với tỷ lệ bằng nhau. Chúng ta có thể nghĩ về những số nguyên này được viết trên những tờ giấy và trộn lẫn trong một chiếc hộp, được lưu trữ trong một bảng (chẳng hạn như bảng số ngẫu nhiên) hoặc được tạo trong một tệp máy tính. Vì tất cả các số nguyên xuất hiện với tỷ lệ bằng nhau, nên biểu đồ tần số tương đối, cho thấy sự phân bố của các

phép đo tổng thể, như được hiển thị trong Hình 3.1.

FIGURE 3.1

Distribution of population containing integers 0 through 9 with equal frequency



Nếu một số được chọn ngẫu nhiên (ví dụ: nếu ai đó rút một tờ giấy ra một cách ngẫu nhiên), thì xác suất chọn được số 4 là $1/10$. Giả sử y là số chọn được từ tập hợp gồm các số 0, 1, 2,..., 9. Xác suất để chọn được y ký hiệu là $p(y)$. Như vậy, đối với tổng thể này,

$$p(0) = p(1) = \cdots = p(8) = p(9) = \frac{1}{10}$$

$$E(y) = \sum_y y p(y)$$

For the population and random variable y under study,

$$\begin{aligned} E(y) &= \sum_y y p(y) \\ &= 0p(0) + 1p(1) + 2p(2) + \cdots + 8p(8) + 9p(9) \\ &= \frac{1}{10}(45) = 4.5 \end{aligned}$$

Chúng ta có thể thấy rằng $E(y)$ bằng **giá trị kỳ vọng**, hoặc giá trị trung bình, của tất cả các phép đo trong tổng thể khái niệm của chúng ta. Nhìn chung, giá trị trung bình của tổng thể sẽ được ký hiệu là $\mu = E(y)$.

Độ biến thiên của các phép đo trong một tổng thể có thể được đo bằng **phương sai**, được định nghĩa là giá trị kỳ vọng hoặc giá trị trung bình của bình phương độ lệch giữa phép đo y được chọn ngẫu nhiên và giá trị trung bình μ của nó. Do đó, phương sai của y , được đưa ra bởi

$$V(y) = E(y - \mu)^2 = \sum_y (y - \mu)^2 p(y)$$

For the population used for illustration in this section,

$$\begin{aligned}
 V(y) &= E(y - \mu)^2 = \sum_y (y - \mu)^2 p(y) \\
 &= (0 - 4.5)^2 \left(\frac{1}{10}\right) + (1 - 4.5)^2 \left(\frac{1}{10}\right) + \cdots + (9 - 4.5)^2 \left(\frac{1}{10}\right) \\
 &= \frac{1}{10} [(0 - 4.5)^2 + (1 - 4.5)^2 + \cdots + (9 - 4.5)^2] \\
 &= \frac{1}{10} (82.5) = 8.25
 \end{aligned}$$

Variance $V(y)$ is commonly denoted by σ^2 .

The *standard deviation* (SD) is defined as the square root of the variance, and it is denoted by $\sigma = \sqrt{\sigma^2}$. For the specific population under discussion,

$$\sigma = \sqrt{8.25} = 2.9$$

Following the pattern set for summarizing the information in a population, we can calculate the mean, the variance, and the SD of a sample. These numerical descriptive measures are given, respectively, by

$$\begin{aligned}
 \bar{y} &= \frac{1}{n} \sum_{i=1}^n y_i \\
 s^2 &= \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n - 1} \\
 s &= \sqrt{s^2}
 \end{aligned}$$

Note that s^2 has the divisor $(n - 1)$ instead of n .

Because the sample mean is one of the most widely used statistics, it is essential to know two of its other properties, namely, its mean and variance. For randomly selected samples from infinite populations, mathematical properties of expected value can be used to derive the facts that

$$E(\bar{y}) = \mu$$

and

$$V(\bar{y}) = \frac{\sigma^2}{n}$$

It can also be shown that the variance of the sample mean can be estimated unbiasedly by

$$\hat{V}(\bar{y}) = \frac{s^2}{n}$$

3.3 Tóm tắt thông tin trong tổng thể và mẫu: Trường hợp tổng thể hữu hạn

Phần trước trình bày kết quả cho lấy mẫu ngẫu nhiên từ một tổng thể được coi là vô hạn. Trong những tình huống như vậy, mỗi phần tử được lấy mẫu có cùng cơ hội được chọn và các lựa chọn độc lập với nhau. Các điều kiện này không được thỏa mãn đối với hầu hết các vấn đề lấy mẫu vì tổng thể được lấy mẫu thường là hữu hạn (mặc dù kích thước của nó là $\mathbf{N}$, có thể rất lớn).

Ngoài ra, các ước lượng thường có thể được cải thiện bằng cách thay đổi xác suất mà các đơn vị được lấy mẫu từ tổng thể. Ví dụ: giả sử chúng ta muốn ước lượng tổng số vị trí tuyển dụng trong một thành phố bằng cách lấy mẫu các công ty trong thành phố đó. (**Ước lượng tổng số chỉ có ý nghĩa khi tổng thể được nghiên cứu là hữu hạn.**) Thông thường, nhiều công ty như vậy sẽ nhỏ và sử dụng ít công nhân, trong khi một số công ty sẽ lớn và sử dụng nhiều công nhân. Trong một mẫu ngẫu nhiên của các công ty, quy mô của các công ty không được tính đến và một mẫu điển hình sẽ bao gồm chủ yếu là các công ty nhỏ. Tuy nhiên, số lượng vị trí tuyển dụng bị ảnh hưởng nặng nề bởi các công ty lớn. Do đó, có vẻ như ước lượng về số lượng vị trí tuyển dụng có thể được cải thiện bằng cách cho các công ty lớn cơ hội xuất hiện trong mẫu lớn hơn. **Minh họa về các nguyên tắc cơ bản của lấy mẫu xác suất được đưa ra ở phần tiếp theo, bắt đầu bằng cách lấy mẫu có hoàn lại để đảm bảo tính độc lập giữa các lựa chọn mẫu và sau đó chuyển sang tình huống thực tế hơn là lấy mẫu không hoàn lại.** Những ý tưởng chung này sẽ được điều chỉnh cho các thiết kế lấy mẫu cụ thể trong các chương sau.

Giả sử tổng thể là một tập hợp các phần tử $\{u_1, u_2, \dots, u_N\}$ và một mẫu gồm n phần tử sẽ được chọn **có hoàn lại**, các phần tử được lấy mẫu được chọn độc lập với nhau. Hơn nữa, gọi $\{\delta_1, \delta_2, \dots, \delta_n\}$ tương ứng là xác suất chọn tương ứng các phần tử này (δ_i là xác suất u_i được chọn trên bất kỳ lần rút thăm nào). Đối với trường hợp lấy mẫu ngẫu nhiên có hoàn lại, mỗi $\delta_i = 1/N$.

Từ tập hợp lớn đó, ta chọn ra một mẫu gồm n ký hiệu là $\{y_1, y_2, \dots, y_n\}$. Để đơn giản hóa ký hiệu, chúng ta có thể nghĩ đến việc sắp xếp lại các δ sao cho sau khi chọn mẫu, δ_i là xác suất chọn được phần tử thứ i trong mẫu là y_i .

Ước lượng không chệch cho population total τ được cho bởi

$$\hat{\tau} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{\delta_i}$$

Ước lượng này là không chệch cho bất kỳ lựa chọn nào của δ . Điểm mấu chốt ở đây là việc **chọn xác suất lấy mẫu δ_i sao cho phương sai của ước lượng là nhỏ nhất.**

- Trong trường hợp đặc biệt, nếu giá trị y_i (trong số N đơn vị lấy mẫu của tổng thể) và population total τ được biết, chúng ta có thể chọn mỗi đơn vị lấy mẫu với xác suất tỷ lệ với. Tức là, chúng ta có thể chọn

$$\delta_i = \frac{y_i}{\tau}$$

Khi đó

$$\hat{\tau} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{\delta_i} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{y_i/\tau} = \tau$$

Như vậy, $\hat{\tau}$ ước lượng τ một cách chính xác. Điều này cho thấy nếu ta có thể chọn xác suất lấy mẫu một cách tối ưu (tức là tỉ lệ với giá trị thực của các phần tử), **ước lượng sẽ hoàn hảo và không có sai số.**

- Trường hợp **không thể biết các giá trị y_i** trong tổng thể trước khi lấy mẫu (bởi nếu chúng đã biết, thì không cần lấy mẫu). Thay vì chọn δ_i như trên, chúng ta sẽ **chọn δ_i tỷ lệ với một phép đo đã biết có tương quan cao với y_i .**

VD: Trong bài toán ước lượng tổng số vị trí tuyển dụng, các công ty có thể được lấy mẫu với xác suất tỷ lệ với tổng số lao động của họ, điều này cần được biết khá chính xác trước khi lấy mẫu. Số lượng vị trí tuyển dụng cho mỗi công ty không được biết trước khi lấy mẫu, **nhưng nó phải có tương quan cao với tổng số công nhân trong công ty.**

Để chỉ ra cách quá trình lấy mẫu hoạt động về mặt số học, giả sử một tổng thể có **N có 4 phần tử, {1, 2, 3, 4}**.

Chọn mẫu với kích thước $n=1$, $E(y) = 2,5$ và $V(y) = 5/4$.

Chọn mẫu với kích thước $n=2$, $E(y^-) = 2,5$ và $V(y^-) = 5/12 = 0,417$.

Chọn mẫu với xác suất không như nhau đối với mỗi phần tử

Giả sử chúng ta quyết định lấy mẫu **có hoàn lại** $n = 2$ với các xác suất khác nhau và chọn $\delta_1 = 0,1$, $\delta_2 = 0,1$, $\delta_3 = 0,4$ và $\delta_4 = 0,4$. Để thực hiện việc lấy mẫu này, chúng ta có thể chọn một chữ số ngẫu nhiên từ bảng số ngẫu nhiên và với cách thức như sau:

1 nếu chữ số ngẫu nhiên là 0

2 nếu chữ số ngẫu nhiên là 1

3 nếu chữ số ngẫu nhiên là 2, 3, 4 hoặc 5

4 nếu chữ số ngẫu nhiên là 6, 7, 8 hoặc 9

Ví dụ: Mẫu kết quả $\{1, 2\}$ nếu chữ số ngẫu nhiên đầu tiên của chúng ta là 0 và chữ số ngẫu nhiên thứ hai của chúng ta là 1 hoặc nếu chữ số ngẫu nhiên đầu tiên của chúng ta là 1 và chữ số ngẫu nhiên thứ hai của chúng ta là 0.

Các điểm chính:

- **Lấy mẫu lần hai:** Sau khi lấy được phần tử đầu tiên, ta lặp lại quá trình để lấy phần tử thứ hai. Điều quan trọng là **có thể lấy trùng phần tử**. Nghĩa là, phần tử đã được chọn ở lần đầu vẫn có thể được chọn lại ở lần hai.
- **Ảnh hưởng của xác suất không đồng đều:** Việc gán xác suất (δ_i) khác nhau cho mỗi phần tử dẫn đến việc các giá trị nhỏ hơn (1, 2) có ít khả năng được chọn vào mẫu hơn, trong khi các giá trị lớn hơn (3, 4) có khả năng được chọn cao hơn. Tuy nhiên, cần lưu ý là xác suất này không hoàn toàn tỷ lệ thuận với kích thước của phần tử.
- **Bảng 3.1:** Bảng này liệt kê tất cả các mẫu có thể có (tổng cộng 10 mẫu), xác suất để có được mỗi mẫu, và giá trị ước lượng ($\hat{\tau}$) tương ứng với mỗi mẫu.
- **Ví dụ về mẫu {1, 2}:** Mẫu này được tạo thành nếu số ngẫu nhiên đầu tiên là 0 và số thứ hai là 1, hoặc ngược lại. Giá trị ($\hat{\tau}$) cho mẫu này sau đó được tính toán (công thức tính ($\hat{\tau}$) đã được đề cập ở phần trước của ví dụ).

Việc lấy mẫu lần hai cũng tuân theo quy trình tương tự như lần đầu, với khả năng lấy trùng phần tử. Nó cũng giải thích cách các xác suất (δ_i) ảnh hưởng đến khả năng các phần tử được chọn vào mẫu và giới thiệu về Bảng 3.1, nơi liệt kê tất cả các mẫu có thể có và kết quả ước lượng tương ứng.

Lưu ý rằng các xác suất này không hoàn toàn tỷ lệ với kích thước, nhưng chúng có xu hướng theo hướng đó. Bảng 3.1 chứa danh sách mười mẫu có thể có, xác suất thu được mỗi mẫu và ước lượng được tạo ra từ mỗi mẫu. Tất cả các giá trị được đưa ra trong Bảng 3.1. Từ thông tin đó, chúng ta thấy rằng với **mẫu {1, 2}**

$$\hat{\tau} = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{\delta_i} = \frac{1}{2} \left(\frac{1}{.1} + \frac{2}{.1} \right) = \frac{1}{2} (10 + 20) = 15$$

All $\hat{\tau}$ values are given in Table 3.1. From that information we see that

$$E(\hat{\tau}) = 15(.02) + \left(\frac{35}{4} \right) (.80) + \dots + 10(.16) = 10$$

TABLE 3.1
Probability sampling with replacement

Sample	Probability of sample	$\hat{\tau}$	$\hat{V}(\hat{\tau})$
{1,2}	.01	15	25.0000
{1,3}	.08	35/4	1.5625
{1,4}	.08	10	0
{2,3}	.08	55/4	39.0625
{2,4}	.08	15	25.0000
{3,4}	.32	35/4	1.5625
{1,1}	.01	10	0
{2,2}	.01	20	0
{3,3}	.16	15/2	0
{4,4}	.16	10	0

and so for this example $\hat{\tau}$ is demonstrated to be an unbiased estimator of τ . Also,

$$V(\hat{\tau}) = (15 - 10)^2(.02) + \left[\left(\frac{35}{4} \right) - 10 \right]^2 (.08) + \dots + (10 - 10)^2(.16) = 6.250$$

The fourth column of Table 3.1 shows the estimated variance of $\hat{\tau}$, which is calculated from the formula

$$\hat{V}(\hat{\tau}) = \frac{1}{n} \cdot \frac{1}{n-1} \sum_{i=1}^n \left(\frac{y_i}{\delta_i} - \hat{\tau} \right)^2$$

- Theo các biến có trọng số (y_i/δ_i) , công thức này trông giống như ước lượng cho phương sai s^2/n . Giá trị kỳ vọng của $\hat{V}(\hat{\tau})$ trên tất cả các mẫu có thể có là 6.250, điều này chứng tỏ rằng $\hat{V}(\hat{\tau})$ là ước lượng không chệch của $V(\hat{\tau})$. (Tính chất này thường áp dụng cho các công cụ ước lượng loại này.) **Lấy mẫu có hoàn lại cho phép lý thuyết hoạt động dễ dàng, nhưng đó là một phương pháp không hiệu quả và không thực tế đối với hầu hết các tình huống lấy mẫu thực tế.** Lấy mẫu có hoàn lại (sampling with replacement) cho phép việc tính toán lý thuyết dễ dàng hơn vì xác suất chọn một phần tử luôn không đổi qua các lần lấy. **Thực tế:** Lấy mẫu không hoàn lại thực tế hơn, nhưng nó làm cho xác suất chọn một phần tử thay đổi sau mỗi lần lấy. Ví dụ, nếu bạn chọn một phần tử từ một quần thể 4 phần tử, xác suất chọn nó ở lần đầu là 1/4. Nhưng nếu phần tử đó đã được chọn, xác suất chọn các phần tử còn lại sẽ thay đổi ở lần lấy thứ hai (chỉ còn 1/3 hoặc 0).

Vì vậy, chúng ta hãy tìm hiểu ước lượng population total **bằng cách lấy mẫu không hoàn lại.**

VD: Giả sử từ tổng thể {1, 2, 3, 4}, lấy mẫu kích thước $n=2$ để **ước lượng population total τ .**

Giải thích về cách ước lượng tổng của một quần thể khi sử dụng phương pháp **lấy mẫu không hoàn lại (sampling without replacement).**

- Giải pháp:** Để giải quyết vấn đề xác suất thay đổi, người ta sử dụng xác suất chọn trung bình của một phần tử (u_i) trên tất cả n lần lấy mẫu. Xác suất trung bình này được ký hiệu là π_i .

- **Công thức ước lượng:** Bằng cách sử dụng xác suất trung bình này, ước lượng ($\hat{\tau}$) cho tổng quần thể

$$\hat{\tau} = \sum_{i=1}^n \frac{y_i}{\pi_i}$$

được định nghĩa bằng công thức:

- **Ý nghĩa:** Công thức này cho thấy mỗi giá trị yi trong mẫu được **đánh trọng số (weighted)** bằng nghịch đảo của xác suất chọn được nó ($1/\pi_i$). Điều này có nghĩa là **các phần tử có xác suất được chọn thấp sẽ được gán một trọng số lớn hơn trong quá trình ước lượng, nhằm điều chỉnh sự thiếu sót của chúng trong mẫu.**

$$\hat{\tau} = \sum_{i=1}^n w_i y_i$$

- **Dạng khác:** Nếu ta đặt $w_i = 1/\pi_i$, công thức sẽ trở thành:

Giải thích về việc lấy mẫu không hoàn lại (sampling without replacement) và so sánh các ước lượng (estimators) trong hai trường hợp: xác suất chọn đều (equal probabilities) và xác suất chọn không đều (unequal probabilities).

Ước lượng τ với Xác suất chọn đều

- Trong trường hợp đơn giản nhất, khi mỗi phần tử của quần thể có xác suất được chọn như nhau, việc tính toán ước lượng tổng quần thể (τ^e) rất dễ dàng.
- Với một quần thể có 4 phần tử {1, 2, 3, 4} và cỡ mẫu $n=2$, có tổng cộng 6 mẫu có thể được chọn. Mỗi mẫu có xác suất được chọn là $1/6$.
- Ví dụ, mẫu {1,2} có ước lượng $\tau^e=6$, và các ước lượng khác được liệt kê trong Bảng 3.2.

TABLE 3.2
Probability sampling without replacement

Sample	Probability of sample, equal weights	$\hat{\tau}_e$	Probability of sample, unequal weights	$\hat{\tau}_u$
{1,2}	1/6	6	.0222	12.2748
{1,3}	1/6	8	.1111	8.0624
{1,4}	1/6	10	.1111	9.3860
{2,3}	1/6	10	.1111	12.1540
{2,4}	1/6	12	.1111	13.4776
{3,4}	1/6	14	.5333	9.2652

Ước lượng với Xác suất chọn không đều

- Khi xác suất được chọn của các phần tử là không đều, giả sử là 0,1, 0,1, 0,4 và 0,4, tương ứng cho bốn phần tử tổng thể, việc tính toán trở nên phức tạp hơn. Khi đó, xác suất để chọn được mẫu {1,3} tính như sau $P(\{1,3\})$
 $= P[(1 \text{ trong lần rút thăm đầu tiên, } 3 \text{ trong lần thứ hai}) \text{ hoặc } (3 \text{ trong lần rút thăm đầu tiên, } 1 \text{ trong lần thứ hai})]$
 $= (0,1)(0,4/0,9) + (0,4)(0,1/0,6) = 0,1111$
(/0.9 do đã lấy phần tử 1 có xác suất 0.1 ra rồi)
- Cộng các xác suất cho ba mẫu chứa phần tử 1, chúng ta thấy rằng $\pi_1 = 0,2444$. Tương tự, $\pi_2 = 0,2444$, $\pi_3 = 0,7555$ và $\pi_4 = 0,7555$. Do đó, các trọng số là $w_1 = 4.0916$, $w_2 = 4.0916$, $w_3 = 1.3236$ và $w_4 = 1.3236$.

- Sau khi tính toán xác suất được chọn trung bình (π_i) cho mỗi phần tử, ước lượng (τ^u) được tính bằng cách nhân mỗi giá trị mẫu với trọng số là nghịch đảo của xác suất được chọn. ($1/0,2444 \times 1 + 1/0,2444 \times 2 = 12,2748$)

So sánh các Ước lượng

- Tính không chệch (Unbiasedness):** Cả hai ước lượng $\hat{\tau}_e$ và $\hat{\tau}_u$ đều là **không chệch** (unbiased), nghĩa là $E(\hat{\tau}_e) = E(\hat{\tau}_u) = 10$.
- Phương sai (Variance):**
 - Phương sai của ước lượng với xác suất chọn đều: $V(\hat{\tau}_e) = 6.667$.
 - Phương sai của ước lượng với xác suất chọn không đều: $V(\hat{\tau}_u) = 2.7212$.
 - Kết quả cho thấy ước lượng với xác suất chọn không đều có **phương sai nhỏ hơn** đáng kể. Điều này có nghĩa là nó cho kết quả ước lượng chính xác hơn và ổn định hơn.

Kết luận

- Lấy mẫu **không hoàn lại** thường hiệu quả hơn lấy mẫu có hoàn lại vì nó cho phương sai nhỏ hơn.
- Lấy mẫu với xác suất thay đổi** (variable probabilities) có thể làm giảm phương sai của ước lượng, từ đó giúp ước lượng chính xác hơn, đặc biệt nếu xác suất được chọn của một phần tử tỷ lệ với kích thước của nó.
- Tầm quan trọng của việc chọn xác suất: Nếu xác suất được chọn không được thiết lập đúng cách, phương pháp này có thể dẫn đến phương sai lớn hơn. Trong ví dụ, với mẫu có kích thước $n=2$ từ tổng thể $\{1,2,3,4\}$, nếu ta chọn xác suất không phù hợp ($\delta_1 = 0,4$, $\delta_2 = 0,4$, $\delta_3 = 0,1$ và $\delta_4 = 0,1$), giá trị ước lượng vẫn không chệch, nhưng phương sai của nó lên tới 81.25. Con số này rất lớn, cho thấy ước lượng kém chính xác.
- Việc ước lượng phương sai của τ^u từ một mẫu đơn lẻ trong trường hợp lấy mẫu không hoàn lại với xác suất không đều là không hề dễ. Việc nghiên cứu các phương pháp thiết kế mẫu tốt hơn để đạt được xác suất chọn đều sẽ được bàn luận trong các chương tiếp theo.

3.4 Phân phối lấy mẫu

Trong các chương sau, các đặc trưng mẫu, chẳng hạn trung bình mẫu $\bar{y}$, sẽ được sử dụng rộng rãi để suy luận về các đại lượng của tổng thể (chưa biết); do đó, chúng ta phải nghiên cứu các tính chất của một số hàm nhất định của các quan sát mẫu.

Xét tổng thể được thảo luận trong Phần 3.2, trong đó **các số nguyên 0, 1,..., 9 được chọn với xác suất bằng nhau**. Từ tổng thể này, lấy 50 mẫu, mỗi mẫu có kích thước $n = 10$ (mỗi mẫu được chọn **có hoàn lại** theo cách tương tự như phương pháp được sử dụng cho một mẫu được chọn trong Phần 3.2. **Bảng 3.3** liệt kê các giá trị trung bình mẫu $\bar{y}$ của 50 mẫu này theo thứ tự tăng dần.


Hình 3.2 vẽ biểu đồ tần suất cho 50 giá trị trung bình mẫu. Phân phối xác suất thực nghiệm này gần đúng với phân phối lấy mẫu lý thuyết của $\bar{y}$.

TABLE 3.3

Sample means for 50 samples, each of size $n = 10$

2.3	3.6	4.1	4.3	4.8
2.6	3.7	4.1	4.3	4.8
2.6	3.7	4.1	4.4	4.8
3.2	3.7	4.1	4.5	4.9
3.3	3.8	4.2	4.7	5.0
3.4	3.9	4.3	4.7	5.1
3.5	4.0	4.3	4.7	5.3
3.5	4.1	4.3	4.8	5.5
3.6	4.1	4.3	4.8	6.0
3.6	4.1	4.3	4.8	6.6

FIGURE 3.2

Distribution of sample means from random digits, $n = 10$ 

Lưu ý rằng phân phối của $\bar{y}$ có xu hướng tập trung gần với giá trị trung bình tổng thể là $\mu = 4,5$, có độ phân tán (hoặc biến thiên) ít hơn nhiều so với các phép lấy mẫu ban đầu.

Chúng ta biết rằng phân phối lấy mẫu của $\bar{y}$ sẽ xấp xỉ $N(\mu, \frac{\sigma^2}{n})$. Biểu đồ hiển thị 50 giá trị trung bình mẫu này có trung bình là 4,22 (gần với $\mu = 4,5$) và độ lệch chuẩn là 0,79 (gần với $\sigma/\sqrt{n} = 2,9/\sqrt{10} = 0,92$). Ngoài ra, biểu đồ tần suất có xu hướng là hình chuông, mặc dù nó không hoàn toàn đối xứng. Những dữ kiện liên quan đến đáng điệu của giá trị trung bình mẫu rất quan trọng trong việc phát triển các quy trình suy luận.

Từ các tính chất đã biết của đường cong chuẩn, trong lấy mẫu hoàn lại, suy ra rằng khoảng 68% giá trị của $\bar{y}$ sẽ nằm trong khoảng ± 1 độ lệch chuẩn của $\bar{y}$. Khoảng 95% giá trị của $\bar{y}$, trong lấy mẫu lặp lại, sẽ nằm trong khoảng ± 2 độ lệch chuẩn độ lệch chuẩn của $\bar{y}$.

Trong ví dụ này, người ta lấy một mẫu gồm 50 giá trị trung bình ($\bar{y}$). Khi kiểm tra, họ thấy có **39** trong số **50** giá trị này nằm trong khoảng 1 độ lệch chuẩn so với giá trị trung bình của mẫu, tương ứng với tỷ lệ $39/50 = \mathbf{78\%}$. Trong 50 giá trị trung bình, có **45** giá trị nằm trong khoảng 2 độ lệch chuẩn, tương ứng với tỷ lệ $45/50 = \mathbf{90\%}$. Tỷ lệ 78% và 90% này cũng được coi là tương đối gần với con số lý thuyết 68% và 95%.

Việc sử dụng **định lý Chebyshev** để ước lượng phạm vi của dữ liệu khi phân phối của chúng không phải là phân phối chuẩn.

- Nếu phân phối mẫu không tuân theo phân phối chuẩn, bạn không thể dùng quy tắc 68-95-99.7. Thay vào đó, bạn có thể dùng định lý Chebyshev.

- **Định lý Chebyshev:** Định lý này khẳng định rằng với bất kỳ tập hợp dữ liệu nào, ít nhất một tỷ lệ nhất định $(1 - 1/k^2)$ của các giá trị sẽ nằm trong khoảng **k độ lệch chuẩn** (k SD) so với giá trị trung bình. Điều này đúng cho bất kỳ giá trị $k \geq 1$.

$$\left[1 - \left(\frac{1}{2}\right)^2\right] = \left(1 - \frac{1}{4}\right) = \frac{3}{4}$$

- **Ví dụ minh họa:** Với $k=2$. Theo định lý, ít nhất $\frac{3}{4}$ các giá trị sẽ nằm trong khoảng 2 độ lệch chuẩn so với giá trị trung bình. Điều này cho thấy rằng, với bất kỳ tập dữ liệu nào, bạn có thể chắc chắn rằng ít nhất 75% dữ liệu nằm trong khoảng 2σ xung quanh giá trị trung bình. Thông thường, phân số này lớn hơn nhiều so với $3/4$.
- **Kết luận:** Vì một tỷ lệ lớn các giá trị (ít nhất 75% với Chebyshev và khoảng 95% với phân phối chuẩn) nằm trong khoảng 2 độ lệch chuẩn so với giá trị trung bình, điều này ngụ ý rằng hầu hết dữ liệu nằm trong phạm vi khoảng 4 độ lệch chuẩn. Từ đó, **độ lệch chuẩn của một tập dữ liệu có thể được ước lượng bằng khoảng một phần tư (1/4) của phạm vi dữ liệu** (phạm vi = giá trị lớn nhất - giá trị nhỏ nhất).

Các thảo luận về phân phối lấy mẫu cho đến nay đã giả định rằng tổng thể mà các mẫu được chọn về cơ bản là **vô hạn**. Nhưng chúng ta có thể muốn làm việc với các tổng thể gồm N phép đo, trong đó N có thể tương đối nhỏ. Vậy thì tính gần đúng chuẩn của phân phối lấy mẫu của $\bar{y}$ có còn đúng không?

Kết quả của một cuộc điều tra thực nghiệm về câu hỏi này như sau.

Giải thích một khái niệm quan trọng trong thống kê: **định lý giới hạn trung tâm (Central Limit Theorem)** và những điều kiện cần để áp dụng nó, đặc biệt khi dữ liệu ban đầu (**population data**) bị lệch (**skewed**).


1. **Vấn đề:** Dữ liệu ban đầu (ở đây là trọng lượng não của 68 con vật) có **phân phối lệch (skewed)**.

TABLE 3.4
Brain weights of selected animals

	Species	Brain weight (in grams)		Species	Brain weight (in grams)
1	African elephant	5712	35	North American opossum	6.3
2	African giant pouched rat	6.6	36	Nine-banded armadillo	10.8
3	Arctic fox	44.5	37	Owl monkey	15.5
4	Arctic ground squirrel	5.7	38	Pig	180
5	Asian elephant	4603	39	Rabbit	12.1
...	...	...	...	...	...
31	Mole rat	3	65	Seal	442
32	Mountain beaver	8.1	66	Walrus	1126
33	Mouse	0.4	67	Porpoise	1735
34	Musk shrew	0.33	68	Blue whale	6800


SOURCE: T. Allison and D. V. Cicchetti, "Sleep in Mammals: Ecological and Constitutional Correlates," *Science* 194 (1976): 732-734.

FIGURE 3.3
Distribution of brain weights of animals



Khi lấy mẫu nhỏ (cỡ mẫu $n=5$) từ dữ liệu này, phân phối của giá trị trung bình mẫu ($\bar{y}$) cũng bị lệch, khiến các phương pháp thống kê cổ điển không hiệu quả


FIGURE 3.4
Distributions of sample means from brain weight data



Lưu ý rằng đối với các mẫu có kích thước 5, phần lớn độ lệch của tổng thể vẫn tồn tại và các phương pháp thống kê cổ điển sẽ không hoạt động tốt trong tình huống này. Bằng chứng về độ lệch trong phân phối của các giá trị trung bình mẫu biến mất khi kích thước mẫu đạt 40.

2. **Giải pháp (tăng cỡ mẫu):** Khi cỡ mẫu đủ lớn ($n=40$), phân phối của giá trị trung bình mẫu trở nên gần với phân phối chuẩn hơn, làm cho các phương pháp thống kê cổ điển trở nên hiệu quả. **Nguyên lý này được gọi là Định lý giới hạn trung tâm.** Nó nói rằng, với cỡ mẫu đủ lớn, phân phối của trung bình mẫu sẽ xấp xỉ phân phối chuẩn, bất kể hình dạng của phân phối ban đầu.
3. **Giải pháp thay thế (biến đổi dữ liệu):** Nếu không thể lấy mẫu lớn, một cách khác là **biến đổi dữ liệu** ban đầu để làm cho phân phối của nó bớt lệch hơn.
 - o **Ví dụ:** Áp dụng phép biến đổi logarit tự nhiên (**natural log**) cho dữ liệu trọng lượng não. Dữ liệu sau khi biến đổi logarit có phân phối gần chuẩn hơn.
 - o **Kết quả:** Với dữ liệu đã được biến đổi, ngay cả các mẫu nhỏ ($n=5$) cũng có thể tạo ra phân phối mẫu gần chuẩn.

FIGURE 3.5
Distribution of $\ln$ (brain weights)



4. Các vấn đề về cỡ mẫu (n) và cỡ tổng thể(N):

- o **Mẫu phải đủ lớn:** Cỡ mẫu cần đủ lớn để đảm bảo phân phối của trung bình mẫu gần chuẩn.
- o **Mẫu không quá lớn:** Cỡ mẫu không nên quá gần với cỡ quần thể. Nếu n rất gần N (ví dụ: $n=60$, $N=68$), phân phối của trung bình mẫu có thể bị "chặt cứng" (**truncated**), và các phương pháp thống kê trong sách sẽ không còn phù hợp. Nếu $n=N$, không cần suy luận thống kê vì bạn đã có toàn bộ dữ liệu.


Các phương pháp suy luận thống kê (inferential methods) hoạt động tốt, **phân phối của trung bình mẫu phải có dạng gần chuẩn**. Điều này có thể đạt được bằng hai cách:

1. Lấy một **cỡ mẫu đủ lớn** (dựa trên Định lý giới hạn trung tâm).
2. Nếu không thể lấy mẫu lớn, hãy **biến đổi dữ liệu** ban đầu để làm cho phân phối của nó bớt lệch hơn.

Đối với các mẫu nhỏ, điều quan trọng là phân phối của dữ liệu tổng thể phải có hình dạng gần giống với hình dạng chuẩn hoặc ít nhất là không quá lệch. Điều này thường có thể được thực hiện bằng cách **chuyển đổi dữ liệu sang một thang đo khác**. Logarit là một phép biến đổi rất hữu ích để xem xét đối với dữ liệu có phân phối với đuôi dài theo hướng dương. **Hình 3.5** cho thấy phân phối logarit tự nhiên của trọng lượng não. Đối với tổng thể được biến đổi này, ngay cả các mẫu nhỏ cũng sẽ tạo ra các phân phối lấy mẫu gần như có hình dạng chuẩn, như có thể thấy trong **Hình 3.6(a) và (b)**. Có vẻ như phân phối lấy mẫu với $n = 60$ (trong số $N = 68$ phép đo trong tổng thể) không gần với hình dạng chuẩn, nhưng việc phóng to biểu đồ này trong **Hình 3.7** cho thấy một số điểm tương đồng với dạng chuẩn. Tuy nhiên, cần lưu ý rằng đuôi của phân phối này ngắn hơn một chút so với kỳ vọng đối với phân phối chuẩn thực sự.

Đối với tổng thể hữu hạn, chúng ta có hai vấn đề về kích thước mẫu cần xem xét. Mẫu phải đủ lớn để đảm bảo tính gần chuẩn của phân phối lấy mẫu của giá trị trung bình mẫu $\bar{y}$, nhưng không quá gần với population total đến mức phân phối lấy mẫu bị chặt cứng. Nếu tình huống thứ hai xảy ra, các phương pháp tổng quát hơn so với các phương pháp được thảo luận trong cuốn sách này có thể được sử dụng. Rõ ràng, nếu $n = N$, thì không cần suy luận thống kê để ước lượng giá trị trung bình tổng thể. Tóm lại, n , N và $N-n$ đều phải khá lớn để các phương pháp suy luận được sử dụng trong các chương sau hoạt động tốt.


FIGURE 3.6
Sampling distributions of sample means from $\ln(\text{brain weights})$
a. Histograms



Histograms (Biểu đồ tần suất)

Các biểu đồ này cho thấy sự thay đổi hình dạng của phân phối trung bình mẫu khi cỡ mẫu (n) tăng từ 5 đến 60.

- **$n=05$:** Biểu đồ có hình dạng rộng và không đều. Điều này phản ánh phân phối ban đầu (cân nặng não) bị lệch. Phân phối của trung bình mẫu cũng bị lệch.
- **$n=10$:** Biểu đồ đã bắt đầu co lại và tập trung hơn.
- **$n=40$:** Hình dạng biểu đồ đã trở nên gần với **phân phối chuẩn** hơn. Phần lớn dữ liệu tập trung xung quanh giá trị trung bình. Điều này minh họa cho **định lý giới hạn trung tâm**.
- **$n=60$:** Biểu đồ càng tập trung hơn nữa, nhưng như đoạn văn có đề cập, khi cỡ mẫu quá gần với cỡ tổng thể ($N=68$), phân phối có thể bị "cắt cụt" (truncated) và không hoàn toàn tuân theo phân phối chuẩn.



Kết luận chung: Cả hai loại biểu đồ đều minh họa cùng một điểm: khi **cỡ mẫu (n) tăng**, sự phân tán của các giá trị trung bình mẫu **giảm** và hình dạng của phân phối trở nên **gần với phân phối chuẩn hơn**.

Các biểu đồ hộp trong **Hình 3.6(b)** cho thấy tất cả các phân phối lấy mẫu đều tập trung gần 2,98, giá trị trung bình của tổng thể ln(trọng lượng não), nhưng có biến thiên giảm dần khi kích thước mẫu tăng lên. Trong trường hợp tổng thể vô hạn, độ lệch chuẩn của $\bar{y}$ phải xấp xỉ $s/\sqrt{n}$. Quy tắc tương tự này có còn đúng trong trường hợp tổng thể hữu hạn không?

FIGURE 3.7
Sampling distribution of sample means; $n = 60$




TABLE 3.5
Summary statistics for sampling distributions of sample means

Statistic	$n = 5$	$n = 10$	$n = 40$	$n = 60$
Mean	3.127	2.904	2.977	2.989
Standard deviation	1.200	0.718	0.248	0.113
$\sigma/\sqrt{n}$	1.201	0.849	0.425	0.347
Adjusted $\sigma/\sqrt{n}$	1.156	0.748	0.273	0.119

Đoạn văn này tiếp tục giải thích về cách phân phối của trung bình mẫu (sample means) thay đổi khi cỡ mẫu (n) tăng lên, tập trung vào hai hình minh họa: biểu đồ tần suất (histogram) cho $n=60$ và một bảng tóm tắt các số liệu thống kê.

Hình 3.7: Biểu đồ này đưa ra phân phối của trung bình mẫu khi cỡ mẫu **rất lớn** ($n=60$, gần với cỡ tổng thể $N=68$). Biểu đồ này cho thấy gần giống hình dạng giống quả chuông. Tuy nhiên, "đuôi" (tails) của phân phối này hơi ngắn hơn so với một phân phối chuẩn thực sự. Điều này xảy ra khi cỡ mẫu quá gần với cỡ quần thể, gây ra hiện tượng phân phối bị "chặt cụt".

Bảng 3.5 này cung cấp các số liệu cụ thể, giúp chúng ta hiểu rõ hơn sự thay đổi của phân phối mẫu khi n tăng.

- **Hàng "Mean" (Giá trị trung bình):** Giá trị trung bình của mẫu (Mean) khá ổn định và gần với giá trị trung bình thực của tổng thể (2.98), bất kể cỡ mẫu là bao nhiêu. Điều này chứng minh cho tính vững của trung bình mẫu.
- **Hàng "Standard deviation" (Độ lệch chuẩn):** Đây là hàng quan trọng nhất. Nó cho thấy **độ lệch chuẩn của trung bình mẫu giảm đi rõ rệt khi cỡ mẫu tăng lên**.
 - Khi $n=5$, độ lệch chuẩn là 1.200.
 - Khi $n=60$, độ lệch chuẩn chỉ còn 0.113.
 - Điều này xác nhận một nguyên lý cơ bản của thống kê: trung bình của các mẫu lớn hơn sẽ có độ biến động ít hơn.
- **Hàng " σ/n " (Độ lệch chuẩn lý thuyết):** Hàng này thể hiện giá trị độ lệch chuẩn của trung bình mẫu theo lý thuyết, được tính bằng công thức σ/n .
- **Hàng "Adjusted σ/n " (Độ lệch chuẩn đã điều chỉnh):** Hàng này sử dụng công thức điều chỉnh cho trường hợp tổng thể hữu hạn.
- Giải thích rằng các giá trị độ lệch chuẩn thực nghiệm (Standard deviation) khá gần với các giá trị lý thuyết ($\sigma/\sqrt{n}$) khi cỡ mẫu nhỏ, nhưng lại có sự chênh lệch đáng kể khi cỡ mẫu lớn hơn (như $n=40$ và $n=60$). Sự chênh lệch này là do việc lấy mẫu từ một **tổng thể hữu hạn** (finite population), và cần phải sử dụng một yếu tố điều chỉnh để tính toán chính xác hơn. Việc điều chỉnh này là một trong những điểm chính được bàn luận ở chương sau.

3.5 Hiệp phương sai và tương quan

Giải thích về sự phụ thuộc giữa hai biến ngẫu nhiên, giới thiệu hai khái niệm quan trọng để đo lường mối quan hệ này: **hiệp phương sai (covariance)** và **hệ số tương quan tuyến tính đơn (simple coefficient of linear correlation)**.

Trong nhiều thí nghiệm, người ta quan tâm đến nhiều hơn một biến số. Ví dụ, một nhà tâm lý học có thể đo lường cả **trí thông minh (y_1)** và **tính cách (y_2)** của một người. Khi đó, câu hỏi đặt ra là: hai biến số này có phụ thuộc vào nhau không và mức độ phụ thuộc là mạnh hay yếu?

Định nghĩa trực quan về sự phụ thuộc: Sự phụ thuộc xảy ra khi giá trị của biến này (ví dụ, y_1) có xu hướng thay đổi theo giá trị của biến kia (ví dụ, y_2). Ví dụ: mối quan hệ giữa tính cách và trí thông minh, hoặc giữa điểm thi đại học và thành tích học tập.


Cách đo lường sự phụ thuộc: Để đo lường sự phụ thuộc, văn bản giới thiệu hai công cụ: **hiệp phương sai (covariance)** và **hệ số tương quan (correlation)**. Các hình vẽ (Figure 3.8a và 3.8b) được sử dụng để minh họa

trực quan: Hai mẫu (ngẫu nhiên) gồm $n = 10$ đơn vị thí nghiệm được rút ra từ một tổng thể. Các phép đo y_1 và y_2 đã được thực hiện trên mỗi đơn vị thí nghiệm.


- Hình 3.8a cho thấy một mối quan hệ **phụ thuộc rõ ràng**: các điểm dữ liệu nằm gần một đường thẳng, nghĩa là khi y_1 thay đổi, y_2 cũng có xu hướng thay đổi theo một quy luật nhất định.
- Hình 3.8b cho thấy **ít hoặc không có sự phụ thuộc**: các điểm dữ liệu nằm rải rác, không theo một mô hình rõ rệt nào.

FIGURE 3.8
Plotted points of two samples

a. Strong positive dependence



b. Little dependence



Giải thích về cách tính toán và ý nghĩa của **hiệp phương sai (covariance)** và **hệ số tương quan (correlation)** để đo lường mối quan hệ tuyến tính giữa hai biến ngẫu nhiên.

Hiệp phương sai (Covariance)

- Cách tính: Hiệp phương sai của hai biến ngẫu nhiên y_1 và y_2 được tính bằng công thức

$$\text{cov}(y_1, y_2) = E[(y_1 - \mu_1)(y_2 - \mu_2)]$$

trong đó μ_1 và μ_2 , tương ứng là giá trị trung bình của y_1 và y_2 .

- Ý nghĩa:

- o Nếu y_1 và y_2 có mối quan hệ tuyến tính dương (khi y_1 tăng thì y_2 cũng có xu hướng tăng), tích $(y_1 - \mu_1)(y_2 - \mu_2)$ sẽ chủ yếu là các giá trị dương, dẫn đến hiệp phương sai dương và có giá trị

"lớn". Giả sử chúng ta biết μ_1 và μ_2 . Bây giờ hãy xác định vị trí một điểm được vẽ trên Hình 3.8(a) và đo các độ lệch, $(y_1 - \mu_1)$ và $(y_2 - \mu_2)$. Các điểm ở bên phải (μ_1, μ_2) sẽ tạo ra các cặp độ lệch dương, trong khi các điểm ở bên trái sẽ tạo ra các cặp độ lệch âm và giá trị trung bình của tích các độ lệch sẽ "lớn" và dương. Nếu quan hệ tuyến tính được chỉ ra trong Hình 3.8(a) dốc xuống về bên phải, thì tất cả các cặp độ lệch tương ứng sẽ có dấu ngược nhau và giá trị trung bình của $(y_1 - \mu_1)(y_2 - \mu_2)$ sẽ là một số âm có giá trị tuyệt đối "lớn".

- o **Giá trị gần bằng 0:** Nếu không có mối quan hệ tuyến tính, các giá trị tích sẽ có cả dấu dương và âm, trung bình lại sẽ gần bằng 0.
- **Hạn chế:** Hiệp phương sai phụ thuộc vào đơn vị đo lường của dữ liệu, khiến việc đánh giá xem một giá trị hiệp phương sai là "lớn" hay "nhỏ" trở nên khó khăn. Giả sử chúng ta có dữ liệu về **Chiều cao** (cm) và **Cân nặng** (kg) của 5 người.

Dữ liệu ban đầu (cm và kg): Giả sử chúng ta tính được hiệp phương sai là **15.0**. Bây giờ, hãy chuyển đổi đơn vị đo chiều cao từ cm sang **mét** (m) và cân nặng từ kg sang **gam** (g).

Chuyển đổi đơn vị: Chiều cao (m) = Chiều cao (cm) / 100 Cân nặng (g) = Cân nặng (kg) * 1000

Dữ liệu sau khi chuyển đổi (m và g): Khi bạn tính lại hiệp phương sai với đơn vị mới, công thức sẽ trở thành: $cov(m,g)=cov(100cm,1000\cdot kg)=1001000\cdot cov(cm,kg)=10\cdot cov(cm,kg)$ Do đó, hiệp phương sai mới sẽ là: $10 \times 15.0 = 150.0$

Mặc dù mối quan hệ giữa chiều cao và cân nặng không hề thay đổi, nhưng giá trị hiệp phương sai đã thay đổi từ **15.0** lên **150.0**. Điều này chứng tỏ hiệp phương sai không phải là một thước đo độc lập với đơn vị, khiến nó không phù hợp để so sánh mức độ phụ thuộc giữa các tập dữ liệu.

Đây là lý do tại sao các nhà thống kê thường sử dụng **hệ số tương quan (correlation)**. Hệ số tương quan được chuẩn hóa, không phụ thuộc vào đơn vị đo, và luôn nằm trong khoảng từ -1 đến 1.

Hệ số tương quan (Correlation)

- **Mục đích:** Để khắc phục hạn chế của hiệp phương sai, người ta sử dụng hệ số tương quan, một thước đo đã được chuẩn hóa.
- **Cách tính:** Hệ số tương quan ρ được tính bằng cách chia hiệp phương sai cho tích của độ lệch chuẩn của từng biến (σ_1 và σ_2). Công thức là:

$$\rho = \frac{cov(y_1, y_2)}{\sigma_1 \sigma_2}$$

- **Ưu điểm và ý nghĩa:**

- o Hệ số tương quan luôn nằm trong khoảng $[-1, 1]$.
- o Giá trị gần 1 hoặc -1 cho thấy mối quan hệ tuyến tính mạnh.
- o Giá trị gần 0 cho thấy ít hoặc không có mối quan hệ tuyến tính.
- o Vì đã được chuẩn hóa, hệ số tương quan dễ dàng được sử dụng để so sánh mức độ phụ thuộc giữa các cặp biến khác nhau.

Tóm lại, cả hiệp phương sai và hệ số tương quan đều là công cụ để đo lường mối quan hệ tuyến tính giữa các biến. Tuy nhiên, **hệ số tương quan được ưu tiên sử dụng hơn** vì nó đã được chuẩn hóa, cho phép chúng ta so sánh và đánh giá mức độ phụ thuộc một cách khách quan hơn. Hệ số tương quan mẫu được sử dụng làm công cụ ước lượng của ρ ; điều này được thảo luận trong Chương 6.

3.6 Ước lượng

Giải thích về các khái niệm cơ bản của **suy luận thống kê (statistical inference)**, tập trung vào việc ước lượng các đặc trưng của một tổng thể từ dữ liệu của một mẫu.

Ước lượng và các tính chất mong muốn

- Một **ước lượng** ($\hat{\theta}$) là một giá trị được tính toán từ dữ liệu mẫu để ước lượng một tham số chưa biết của tổng thể (θ). Ví dụ phổ biến nhất là **trung bình mẫu** ($\bar{y}$), dùng để ước lượng **trung bình tổng thể** (μ). (Lưu ý rằng $\bar{y}$, tuy nhiên, là một biến ngẫu nhiên và có phân phối xác suất hoặc phân phối lấy mẫu phụ thuộc vào cơ chế lấy mẫu, như đã chỉ ra trong Phần 3.4. Một số giá trị có thể có mà $\bar{y}$ có thể nhận sẽ gần với μ và các giá trị khác có thể khá xa μ ở phía dương hoặc phía âm.)
- Một ước lượng tốt cần có hai tính chất chính:
 - Không chệch (Unbiased):** $E(\hat{\theta}) = \theta$ Giá trị trung bình của ước lượng phải bằng đúng giá trị của tham số tổng thể mà nó đang ước tính. Tức là, nếu lấy nhiều mẫu và tính trung bình các giá trị ước lượng, kết quả sẽ rất gần với tham số thực.
 - Phương sai nhỏ (Small variance):** $Var(\hat{\theta}) = \sigma_{\hat{\theta}}^2$ nhỏ. Các giá trị ước lượng từ các mẫu khác nhau không nên quá khác biệt so với nhau. Điều này cho thấy ước lượng ổn định và chính xác hơn.

Sai số ước lượng (Error of Estimation) và Khoảng tin cậy

- Sai số ước lượng** $|\hat{\theta} - \theta|$ được định nghĩa là độ chênh lệch tuyệt đối giữa giá trị ước lượng và tham số thực. Vì không thể biết chính xác sai số này, chúng ta tìm cách xác định một **giới hạn trên (bound)** cho nó, thường được gọi là **biên độ sai số (margin of error)**, ký hiệu là **B**.
- Khoảng tin cậy (Confidence Interval)** là một khoảng mà chúng ta tin rằng nó chứa tham số tổng thể thực $P(|\hat{\theta} - \theta| < B) = 1 - \alpha$. Khoảng này có dạng $(\hat{\theta} - B, \hat{\theta} + B)$, và độ tin cậy được thể hiện bằng một xác suất, ví dụ 95% hoặc 99%.
- Nếu $\hat{\theta}$ có phân phối chuẩn thì $B = z_{\alpha/2} \sigma_{\hat{\theta}}$. Nếu $1 - \alpha = .95$, thì $z_{.025} = 1.96$, hoặc xấp xỉ 2 để đơn giản.

Phân phối của ước lượng và việc sử dụng phân phối Student's t

- Mặc dù phân phối của trung bình mẫu thường có dạng hình chuông (phân phối chuẩn), nhưng trong thực tế, **độ lệch chuẩn của tổng thể (σ) thường không được biết trước**.
- Trong những trường hợp này, các phương pháp thống kê chính xác hơn sẽ dựa vào **phân phối Student's t** thay vì phân phối chuẩn.
- Tuy nhiên, để đơn giản, **cuốn sách này sẽ tiếp tục sử dụng biên độ sai số 2 SD (dựa trên phân phối chuẩn) như một quy tắc chung**. Điều này cũng hợp lý trong các ứng dụng thực tế, vì khi cỡ mẫu đủ lớn, phân phối t gần với phân phối chuẩn và phương pháp sử dụng z-score vẫn cho kết quả rất tốt.

3.7 Tóm tắt

Chương này đã trình bày một bản tóm tắt ngắn gọn về các khái niệm cơ bản của thống kê, tập trung vào vai trò của các số đo mô tả, lý thuyết xác suất và khái niệm về ước lượng để suy luận về một quần thể.

- **trung bình (mean) và độ lệch chuẩn (standard deviation).** Trong đó:
 - o Trung bình là thước đo dễ hiểu về tâm của dữ liệu (center).
 - o Độ lệch chuẩn chỉ có ý nghĩa khi được diễn giải thông qua các định lý như **Chebyshev** hoặc các phân phối cụ thể như **phân phối chuẩn**.
- **Vai trò của Xác suất:** từ một tổng thể đã biết để phân tích một mẫu.
 - o **Thống kê** làm việc theo chiều ngược lại: sử dụng xác suất làm công cụ để **suy luận** về một quần thể chưa biết, dựa trên thông tin thu được từ một mẫu.
- **Biến ngẫu nhiên và Ước lượng:** Chương cũng đã giới thiệu các tính chất của một **ước lượng (estimators)**, các công cụ dùng để ước tính tham số quần thể. Các khái niệm như **phân phối mẫu**, kỳ vọng, hiệp phương sai và **hệ số tương quan** được sử dụng để đánh giá ước lượng.

- **Lấy mẫu từ tổng thể vô hạn:** Theo thống kê, khi lấy một mẫu ngẫu nhiên có kích thước n từ một tổng thể vô hạn, phương sai của giá trị trung bình mẫu là σ^2/n .
- **Lấy mẫu từ tổng thể hữu hạn:** Khi tổng thể có kích thước hữu hạn (N), ta cần đưa thêm **hiệu chỉnh tổng thể hữu hạn** vào công thức phương sai. Hiệu chỉnh này là yếu tố $(N - n)/N$.
 - Do đó, công thức phương sai được điều chỉnh thành: $\frac{\sigma^2}{n} \times \frac{N-n}{N}$.
 - Tương tự, sai số chuẩn (standard error) cũng được điều chỉnh bằng cách lấy căn bậc hai của yếu tố này, tức là $\sqrt{(N - n)/N}$.
- **Ý nghĩa của fpc:** Yếu tố $(N - n)/N$ luôn nhỏ hơn 1. Điều này có nghĩa là phương sai khi lấy mẫu từ tổng thể hữu hạn sẽ **nhỏ hơn** so với khi lấy mẫu từ tổng thể vô hạn. Điều này là hợp lý, vì khi lấy mẫu từ một tổng thể hữu hạn, mỗi lần chọn một phần tử, số lượng phần tử còn lại để chọn sẽ giảm đi, dẫn đến độ không chắc chắn (phương sai) giảm. Khi kích thước mẫu n gần bằng kích thước tổng thể N , fpc sẽ tiến gần về 0.
- **Khi nào có thể bỏ qua fpc:** Trên thực tế, fpc có thể được bỏ qua nếu **tỷ lệ lấy mẫu (n/N)** nhỏ, thường là khi tỷ lệ này **không vượt quá 5%** (hoặc thậm chí 10% trong một số trường hợp).
 - Lý do là khi n/N rất nhỏ, giá trị của fpc, $(N - n)/N = 1 - n/N$, sẽ rất gần 1. Do đó, việc sử dụng fpc sẽ không tạo ra sự khác biệt đáng kể.
- **Hậu quả của việc bỏ qua fpc:** Nếu bỏ qua fpc khi cần sử dụng, chúng ta sẽ **ước lượng** quá cao sai số chuẩn của **ước lượng**, dẫn đến việc đánh giá sai độ chính xác của kết quả.